[Data description] 데이터 명세

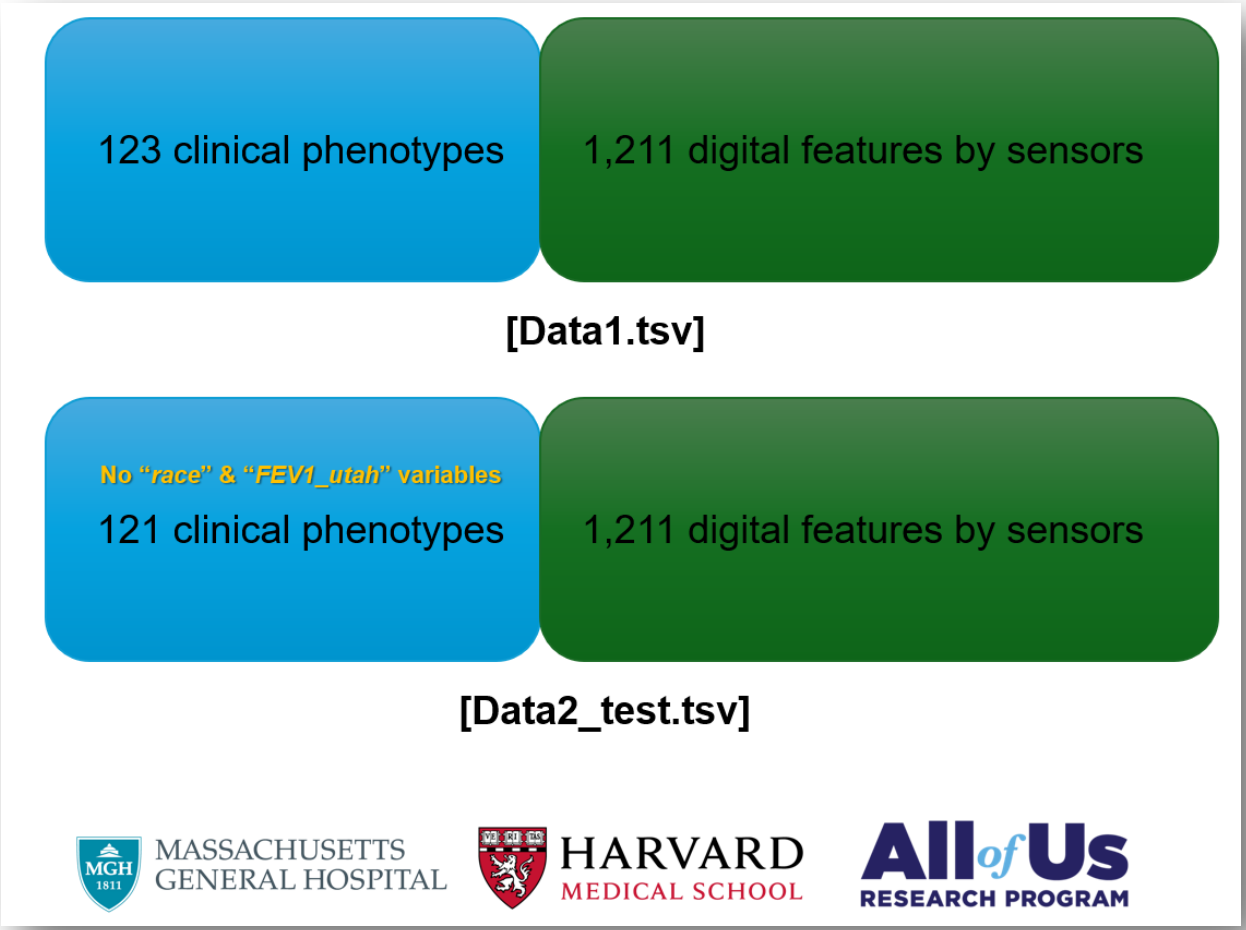

"Data1.tsv" **contains fully preprocessed clinical information (123 variables), including CT-derived features, for a total of 1,500 patients** collected at Massachusetts General Hospital (MGH), one of the affiliated hospitals of Harvard Medical School, which is ranked first among medical schools worldwide. In addition, the dataset includes **digital phenotypes (1,211 variables)** measured using state-of-the-art sensors. Based on these data, please accomplish the tasks requested below and demonstrate to the fullest extent your competencies required to survive and excel in the era of artificial intelligence.

Kor: Data1.tsv에는 세계 의과대학 1위인 하버드 의과대학 부속 병원 중 하나인 MGH에서 수집된 총 1,500명의 환자에 대한 CT 등 모두 전처리된 임상 정보 (123 종)와 최첨단 센서에 의해 측정된 디지털 표현형 (1,211 종)이 포함되어 있습니다. 이를 바탕으로 하단의 요청에 대해서 달성해가며, 인공지능 시대에서 살아남을 수 있는 여러분들의 역량을 마음껏 보여주십시오.

"Data2_test.tsv" follows the same data structure as Data1.tsv but comprises **an independent cohort of 1,000 patients**. In this dataset, two variables are missing: the *race* variable (detailed racial information) and the *FEV1_utah* variable (a quantitative indicator of pulmonary function).

Data2_test.tsv는 Data1.tsv와 같은 형식의 자료지만, 독립적인 총 1,000명의 환자에 대해 두 변수; race 변수 (상세 인종정보) 와 FEV1_utah 변수 (폐기능 정량화 지표)만 누락되어 있는 자료입니다.

[Q1 – Q3] Based on the Data1.tsv only

(Q1). **Using the provided data (Data1.tsv), identify an optimal clustering solution based on the Silhouette score, leveraging the 1,211 sensor-derived digital phenotype features (Feature_1, …, Feature_1211).** Provide a clear and precise specification of the methodology you used, and report the overall mean Silhouette score of your final clustering result in the table below. Grading will be differential, based on the overall mean Silhouette score obtained from an analysis conducted using an appropriate and correct method. **(Max 25 Points)**

Kor: 주어진 자료에서 1,211개의 (Feature_1, …, Feature1211) 센서에 대한 디지털 표현형을 바탕으로 Silhouette 점수를 기반으로 최적화된 군집을 찾으십시오. 찾은 방법론에 대한 명확한 명세와 전체 평균 Silhouette 점수를 하단 테이블에 기술하십시오. 정확한 방법에 의해 실시된 분석결과의 전체 평균 Silhouette 점수를 기반으로 점수는 차등 배점 됩니다.

[Answer]

(Q1-1) Description of your analysis

Data1.tsv에서 센서 기반 디지털 페노타입 변수 Feature_1~Feature_1211만 추출하여 분석에 사용하였다. 변수 스케일 차이가 거리 기반 군집화에 미치는 영향을 제거하기 위해 모든 센서 변수를 Z-score로 표준화하였다. 이후 고차원 공간에서 하위 주성분에 잡음이 포함되어 군집 분리가 흐릿해질 수 있다는 점을 고려하여 PCA로 차원을 축소하고, 누적 설명분산 기준(70~95%) 및 직접 지정한 주성분 개수 후보(3, 5, 7, 9, 12, 15, 20, 23, 30)를 포함하여 여러 nPC 표현을 함께 탐색하였다. 군집의 분리도를 최대화하기 위해 거리(metric)를 유클리드/맨해튼/코사인으로 바꾸어가며 평균 Silhouette score를 계산하고, 2단계 탐색을 수행하였다.

1단계에서는 거리행렬 기반 PAM(k-medoids, diss=TRUE)을 사용하여 (표현×거리) 조합을 빠르게 스크리닝한 뒤 상위 후보를 선별하였다. 2단계에서는 선별된 상위 후보에 대해 PAM, 계층적 군집(complete/average linkage), 그리고 제한적으로 K-means를 비교하고 k범위를 확장하여 평균 Silhouette score가 최대인 조합을 최종 군집해로 선택하였다. 그 결과, PC 3개(nPC=3)로 표현한 PCA 공간에서 코사인 거리 기반으로 K-means를 적용하고 k=3으로 군집화한 경우가 가장 높은 평균 Silhouette score를 보였다.

(Q1-2) Average Silhouette score

0.59609

(Q2). Perform a visualization that supports the analysis results from (Q1), and present it as a single figure. The optimized clustering results should be distinguished using separate colors. **(10 Points)**

Kor: (Q1)의 분석결과를 뒷받침할 수 있는 시각화를 수행하십시오 (그림 1장으로 표현). 최적화된 군집 결과는 별도의 색으로서 표시하십시오.

[Answer]

(Q2-1) Description of your analysis

Q1에서 선택된 최적 군집화 결과를 시각적으로 뒷받침하기 위해, 동일한 PCA 공간에서 표본들의 분포를 2차원으로 투영하여 단일 그림으로 제시하였다. 구체적으로, 최적 조합에서 사용된 주성분 점수(PC 공간) 중 PC1과 PC2를 x축과 y축으로 사용하여 전체 표본을 산점도로 표시하고, 최적 군집화로부터 얻은 클러스터 라벨을 색상으로 구분하여 군집별로 시각적으로 분리되도록 구성하였다.

또한 PCA 축에는 PC1과 PC2의 설명분산 비율(%)을 함께 표기하여, 해당 2차원 투영이 전체 변동 중 어느 정도를 반영하는지 해석 가능하도록 하였다. 이 단일 산점도는 군집 간 분리 정도와 군집 내 응집 정도를 직관적으로 보여주므로, Q1에서 도출된 최적 군집화 결과를 시각적으로 지원하는 목적에 부합한다.

(Q2-2) Figure of your analysis

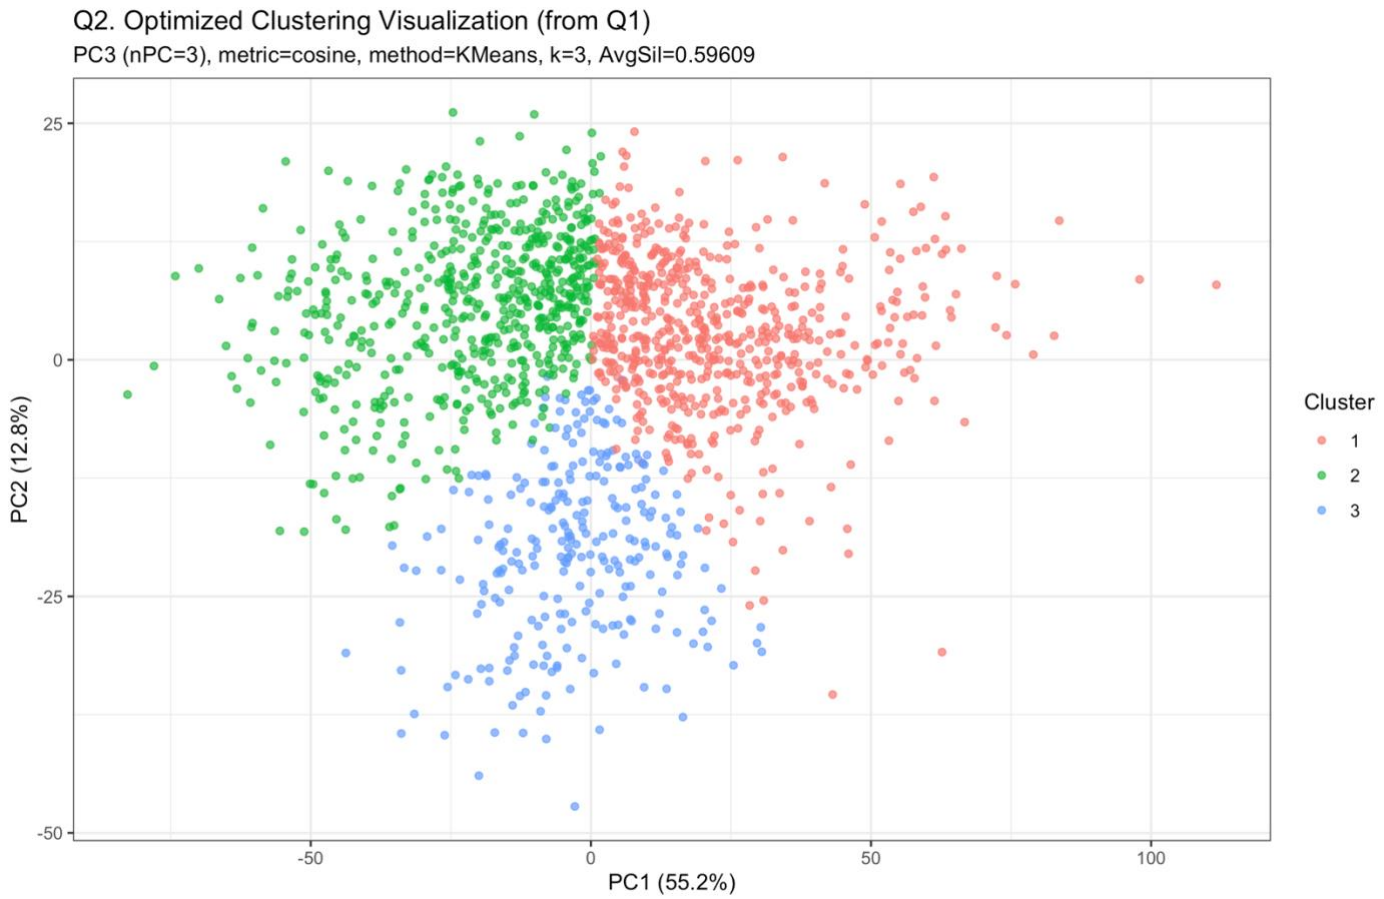

(Q3). **Investigate which clinical variables (among the 123 clinical features) can best explain or characterize the optimized clusters identified in (Q1)**. Based on these findings, provide an appropriate interpretation of the clusters. You must document a clear analytical procedure in writing, and your interpretation must be supported by objective results and a defensible logical argument. **(15 Points)**

Kor: (Q1)에서 찾은 최적화된 군집들은 어떤 임상정보 (총 123종)에 따라 설명될 수 있는지를 찾아보십시오. 그를 바탕으로 적절한 해석에 이르십시오. 이를 해결하기 위한 명확한 분석과정을 글로 남겨야 하며, 객관적 결과로서 논리가 뒷받침되어야 합니다.

[Answer]
(Q3-1) Description of your analysis

(Q1)에서 도출된 최적 군집(PC 3개 기반 표현공간, cosine 거리 기반 평가, row-normalize 후 KMeans, k=3)을 동일한 시드(2025)로 재현하여, 군집 라벨을 고정한 뒤 임상 변수(총 123개)가 이 군집을 "설명/특성화"할 수 있는지 검증했습니다. 군집 자체의 품질은 전체 평균 실루엣이 0.59609이고 군집 크기가 620, 614, 266으로 확인되어, 센서 공간에서는 3개 군집이 의미 있게 분리되어 있음을 먼저 확인했습니다.

임상 변수는 타입을 재분류하여 해석을 안정화했습니다. 0/1 이진 변수는 범주형(factor)으로, 소수 수준의 정수형(유니크 값이 10 이하인 정수형)은 범주형으로, 그 외는 연속형(numeric)으로 처리했습니다. 또한 이름에 'avail'이 포함된 변수(QCT_Thirona_avail)는 임상 상태 자체라기보다 "측정/가용성(데이터 생성 과정)"을 반영할 가능성이 높아 임상 해석용 메인 변수에서 분리하여 별도로 보고했습니다.

첫째, 단변량 관점에서 각 임상 변수가 군집 간 분포 차이를 보이는지 검정했습니다. 연속형은 Kruskal-Wallis 검정과 효과크기(epsilon-squared)를, 범주형/이진형은 카이제곱 검정(기대빈도 희소 시 모의 p-value)과 효과크기(Cramer's V)를 사용했습니다. 이후 122개('avail' 제외 메인 임상 변수)에 대한 다중검정을 BH-FDR로 보정하여, "다중비교를 고려해도 유지되는 임상적 차이"만 남기도록 설계했습니다.

둘째, 다변량 관점에서 임상 변수 전체로 군집 라벨(3-class)을 예측할 수 있는지 Random Forest(ranger)로 검증했습니다. 5-fold 교차검증 정확도를 산출해 임상 정보만으로 군집이 재현 가능한지 확인했고, 추가로 라벨 permutation test(B=200, 동일 폴드 유지)를 통해 관측 정확도가 우연 수준을 유의미하게 상회하는지 통계적으로 검정했습니다. 이는 단순히 "중요 변수 목록"을 제시하는 수준을 넘어, "임상 변수로 군집이 실제로 설명 가능한가"를 정량적으로 반박 또는 지지하기 위한 절차입니다.

셋째, 탐색적으로는 후보 변수 일부에 대해 군집별 평균/비율과 사후 pairwise 비교(연속형: pairwise Wilcoxon BH, 범주형: 각 군집 쌍 검정 후 변수 내부 BH)를 출력해, 만약 약한 차이가 있더라도 어떤 군집 쌍에서 차이가 나타나는지까지 확인했습니다. 다만 이는 어디까지나 보조적 근거이며, 최종 결론은 전체 임상 변수에 대한 BH-FDR 결과와, 임상 기반 군집 예측 가능성(RF + permutation test)에 우선순위를 두었습니다.

(Q3-2) Conclusion

임상 변수('avail' 성격 변수를 제외한 122개)가 최적 군집을 "임상적으로 명확히 규정하는 특성"을 제공한다는 근거는 확인되지 않았습니다. 단변량 검정에서 BH-FDR 5% 기준으로 유의한 메인 임상 변수가 0개였고, 효과크기 역시 전반적으로 매우 작았습니다. 즉, 표본 수가 1500으로 충분히 큰데도 다중비교 보정 후 살아남는 임상 차이가 없다는 점은, 군집이 전통적 임상 변수 축에서 강하게 분리되는 임상 아형이라기보다는 센서 기반 디지털 페노타입 공간에서 나타난 패턴일 가능성이 높다는 해석을 지지합니다.

다변량 결과도 동일한 결론을 강화합니다. 메인 임상 변수로 군집을 예측하는 Random Forest의 5-fold CV 정확도는 0.3980(±0.0115)로, 다수 클래스 베이스라인 정확도 0.4133보다 높지 않았습니다. 또한 라벨을 무작위로 섞었을 때의 정확도 분포와 비교하는 permutation test에서 관측 정확도는 우연 수준을 상회하지 못했으며(p=0.76617), 임상 변수만으로는 이 군집 구조를 재현하거나 설명할 수 없다는 점이 통계적으로 확인되었습니다. 따라서 "임상 변수로 군집을 설명할 수 있다"는 강한 결론을 내리기보다는, "임상적으로는 분리 근거가 약하며, 센서 기반 특징에서만 안정적으로 분리되는 군집"이라는 결론이 가장 방어 가능하고 논리적으로 타당합니다.

한편, 'avail' 변수(QCT_Thirona_avail)는 매우 유의했으나, 이는 건강 상태의 차이라기보다 특정 정량 CT 파생 지표의 '가용성/측정 여부' 차이를 반영할 가능성이 커서, 임상적 군집 해석의 핵심 근거로 사용하는 것은 부적절합니다. 또한 SF36 계열(정신건강/활력/역할 제한 등)과 소득(Income)에서 일부 군집 쌍 비교가 탐색적으로 유의하게 나타나기도 했으나, 전체 임상 변수 다중비교(BH-FDR) 기준으로는 유지되지 않았으므로 확정적인 군집 정의로 쓰기에는 근거가 부족합니다. 종합하면, 이번 최적 군집은 "임상 변수로 명확히 규정되는 아형"이라기보다 "센서 기반 디지털 페노타입에서 발견되는 잠재 패턴"이며, 임상적 해석은 제한적으로만 제시하는 것이 적합합니다.

[Q4 – Q5] Based on the Data1.tsv & Data2_test.tsv

(Q4). **Using *Data1.tsv*, build the best-performing predictive model to estimate detailed race (Race variable)**. Then, apply the selected optimal model to the independent cohort of 1,000 patients in Data2_test.tsv and predict their race. You must compare at least three different models and select the best one. Please enter your predicted results into **Q4_AnswerSheet.xlsx for submission**. As in a datathon setting, scores will be differentially weighted based on prediction accuracy on the test dataset. **(25 Points)**

Kor: Data1.tsv를 바탕으로 세부인종 (Race)를 예측할 수 있는 최적의 예측 모형을 구축하십시오. 찾은 최적의 모형을 바탕으로 Data2_test.tsv의 독립적인 1,000명의 환자들에 적용하여, 그들의 race를 예측해보십시오. 최소 3개의 다른 모형을 비교하여 최고의 모형을 찾으십시오. 예측한 결과는 Q4_AnswerSheet.xlsx 에 기입하여 제출하시길 바랍니다. Datathon처럼 실제 test자료에서의 정확도 순으로 점수는 차등 배점 됩니다.

[Answer]

***Description of your analysis**

Data1(Train)과 Data2(Test) 데이터셋 간의 변수 불일치 문제를 해결하기 위해 Data2에 존재하지 않는 FEV1_utah 변수와 식별자인 sid를 제외한 공통 변수만을 추출하여 분석에 활용하였다. 예측 성능을 극대화하기 위해 변수의 특성에 따른 맞춤형 전처리 전략을 수립하였다. 임상 변수(Clinical Features)의 경우 Train과 Test 데이터를 통합하여 값이 하나뿐인 상수 변수(ethnic)를 제거하고 일관된 기준의 원-핫 인코딩(One-Hot Encoding)을 적용함으로써 데이터 구조의 통일성을 확보하였다. 1,200개 이상의 고차원 센서 변수(Sensor Features)는 차원의 저주를 방지하기 위해 Train 데이터를 기준으로 표준화(Z-score)를 수행한 후 주성분 분석(PCA)을 적용하였으며 교차 검증을 통해 최적의 주성분 개수를 30개로 선정하여 차원을 효율적으로 축소하였다.

인종(Race) 예측 모델을 구축하기 위해 Elastic Net(Glmnet)과 Random Forest 및 Multinomial Logistic Regression 그리고 SVM(Radial Kernel) 등 총 4가지의 상이한 알고리즘을 도입하였고 모델의 일반화 성능을 신뢰성 있게 평가하기 위해 5-Fold Cross-Validation을 수행하였다. 모델 비교 결과 Glmnet 모델이 교차 검증 정확도 100%를 기록하며 가장 우수한 성능을 보여 최적 모델로 선정되었다. 최종적으로 해당 모델을 독립 코호트인 Data2에 적용하여 1,000명의 인종을 예측하고 결과를 산출하였다.

(Q5). **Using *Data1.tsv*, build the best-performing predictive model to predict expiratory pulmonary function (FEV1_utah variable).** Then, apply the selected optimal model to the independent cohort of 1,000 patients in Data2_test.tsv and predict their FEV1_utah values. You must compare at least three different models and select the best one. Please record your predictions in **Q5_AnswerSheet.xlsx for submission**. As in a datathon setting, scores will be differentially weighted according to predictive accuracy on the test dataset. **(25 Points)**

Kor: Data1.tsv를 바탕으로 날숨-폐기능 (FEV1_utah)을 예측할 수 있는 최적의 예측 모형을 구축하십시오. 찾은 최적의 모형을 바탕으로 Data2_test.tsv의 독립적인 1,000명의 환자들에 적용하여, 그들의 날숨-폐기능을 예측해보십시오. 최소 3개의 다른 모형을 비교하여 최고의 모형을 찾으십시오. 예측한 결과는 Q5_AnswerSheet.xlsx 에 기입하여 제출하시길 바랍니다. Datathon처럼 실제 test자료에서의 정확도 순으로 점수는 차등 배점 됩니다.

[Answer]

***Description of your analysis**

연속형 변수인 폐기능 지표(FEV1_utah)를 예측하기 위해 Data1(Train)과 Data2(Test)의 공통 변수를 추출하고 Data2에 존재하지 않는 race 변수는 분석에서 제외하였다. 데이터의 특성을 고려한 전처리 전략으로 임상 변수는 상수 변수 제거 및 원-핫 인코딩을 적용하여 수치형 데이터로 변환하였으며 1,200개 이상의 고차원 센서 데이터는 Train 데이터를 기준으로 표준화 후 주성분 분석(PCA)을 수행하였다. 교차 검증을 통해 최적의 주성분 개수를 10개로 선정하여 차원을 효율적으로 축소하였다.

예측 모델 구축을 위해 Elastic Net(Glmnet)과 Random Forest 및 Gradient Boosting Machine(GBM) 그리고 SVM Regressor(Radial Kernel) 등 4가지 회귀 알고리즘을 비교 분석하였다. 5-Fold Cross-Validation을 통해 모델의 RMSE(Root Mean Squared Error)를 평가한 결과 GBM 모델이 가장 낮은 RMSE(0.4856)를 기록하여 최적 모델로 선정되었다. 최종적으로 선정된 GBM 모델을 활용하여 독립 코호트인 Data2의 1,000명 환자에 대한 FEV1_utah 값을 예측하고 결과를 산출하였다.

-At the end- Well done for one semester!